

# ANALISADOR SEMANTICO DE DEPOIMENTOS E DOCUMENTOS

## 1. Visão Geral do Contexto Operacional

O **Analisador de Documentos e Depoimentos** utiliza Processamento de Linguagem Natural (NLP) e Modelos de Linguagem de Grande Escala (LLMs) para automatizar a triagem de documentos investigativos. Ele resolve o problema da "infoxicação" (excesso de informação), permitindo que o investigador foque nas contradições e nos fatos relevantes, acelerando a conclusão de inquéritos complexos.

---

## 2. Requisitos Funcionais (RF)

| ID   | Requisito                   | Descrição Detalhada                                                                                                      |
|------|-----------------------------|--------------------------------------------------------------------------------------------------------------------------|
| RF01 | Ingestão Documental         | Suporte à leitura e extração de texto de arquivos PDF (incluindo PDFs de imagem via OCR) e DOCX.                         |
| RF02 | Extração de Entidades (NER) | Identificação automática e listagem de Nomes, CPFs, Locais, Organizações e Datas citadas.                                |
| RF03 | Análise de Contradições     | Comparação entre documentos (Ex: Depoimento 1 vs. Depoimento 2) para destacar divergências em datas, horários ou locais. |

|      |                       |                                                                                                                       |
|------|-----------------------|-----------------------------------------------------------------------------------------------------------------------|
| RF04 | Cronologia Automática | Geração de uma linha do tempo dos fatos baseada na narrativa dos documentos processados.                              |
| RF05 | Resumo Executivo      | Produção de sínteses curtas e objetivas, mantendo o contexto jurídico e técnico.                                      |
| RF06 | Citação de Fonte      | Cada afirmação gerada pela IA deve vir acompanhada de um link ou referência à página/parágrafo do documento original. |

---

### 3. Requisitos Não Funcionais (RNF)

| ID    | Requisito         | Critério de Aceite                                                                                                                                              |
|-------|-------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| RNF01 | Baixa Alucinação  | Implementação de técnicas de <b>RAG (Retrieval-Augmented Generation)</b> para garantir que a IA responda apenas com base nos documentos fornecidos.             |
| RNF02 | Privacidade Total | O processamento não deve utilizar APIs públicas (como OpenAI) que usem dados para treinamento. Preferência por modelos <i>Local-LLM</i> ou instâncias privadas. |
| RNF03 | Rastreabilidade   | Logs de auditoria indicando qual usuário processou quais documentos, em conformidade com a LGPD.                                                                |
| RNF04 | Performance       | Capacidade de processar um documento de 50 páginas e gerar o resumo em até 30 segundos.                                                                         |

|       |                    |                                                                                                        |
|-------|--------------------|--------------------------------------------------------------------------------------------------------|
| RNF05 | Interoperabilidade | Exportação dos resultados em formatos compatíveis com os relatórios oficiais da PCDF (PDF e Markdown). |
|-------|--------------------|--------------------------------------------------------------------------------------------------------|

---

## 4. Arquitetura do Sistema

A arquitetura deve priorizar a segurança dos dados e a modularidade dos modelos de IA:

1. **Backend (Python/FastAPI):** Orquestrador principal que gerencia o fluxo de documentos.
2. **Camada de Ingestão (Unstructured/PyMuPDF):** Módulo para "limpar" e converter documentos em texto puro.
3. **Vector Database (ChromaDB/Pinecone Local):** Armazena os "pedaços" (*chunks*) de texto convertidos em vetores para busca semântica (RAG).
4. **LLM Engine (Ollama/vLLM):** Container isolado rodando modelos como **Llama 3** ou **Mistral**, configurados para não reter histórico de chat.
5. **Frontend (React/Streamlit):** Interface focada em leitura comparativa (lado a lado) e visualização de grafos de entidades.

---

## 5. Paridade UnB-PCDF e Infraestrutura

A implementação técnica deve seguir rigorosamente a paridade de ambientes para evitar falhas no deploy final:

- **Dockerização de Modelos:** O modelo de linguagem (LLM) deve estar empacotado em um container Docker, garantindo que as dependências de GPU/CPU sejam as mesmas no laboratório da UnB e nos servidores da PCDF.
- **Esteira DevSecOps:** Uso do **SonarQube** para monitorar vulnerabilidades. O pipeline de CI/CD deve incluir testes de "Sanity Check" para verificar se o modelo não está alucinando em cenários de teste conhecidos.
- **Observabilidade:** Integração com **Grafana** para monitorar o consumo de memória RAM e GPU, crítico em aplicações de NLP.
- **Infraestrutura Pós-Aceite (PCDF):**
  - **Servidores On-Premise:** Equipados com GPUs (ex: NVIDIA A100 ou RTX 4090) para rodar os modelos localmente.
  - **Storage Seguro:** Repositório criptografado para os arquivos temporários processados pela IA.
  - **Rede Isolada:** Acesso restrito via VPN para que os dados do inquérito nunca toquem a internet aberta.

